1. **Arquitetura e Configuração: Descreva a arquitetura geral de uma implementação típica do Databricks. Como você configuraria um ambiente Databricks para otimizar o desempenho e a escalabilidade?**
   R: Para uma implementação do Databricks é necessário ter um Servidor ou um Cluster com a plataforma instalada, com as conexões de origem e destino configurada e habilitada. A partir daí é possível criar notebooks para extração, transformação e carga de dados a partir das origens que pode ser diversas e para o destino final que pode ser diverso também. As origens pode ser um Blob Storage, databases ou até mesmo arquivos. O destino também pode ser um Blob Storage entre as camadas (bronze e silver), que é mais performático e, depois na camada ouro, um banco de dados relacional ou não relacional.
   Uma possível solução para que se tenha desempenho e escalabilidade é configurar o Spark e trabalhar com Blobs entre as camadas. Além disso é possível configurar o Scala para poder realizar cargas nos Databases de destino com maior performance. Por exemplo ao fazer um merge em um banco de dados relacional.
   Abaixo um exemplo de desenho de uma solução.

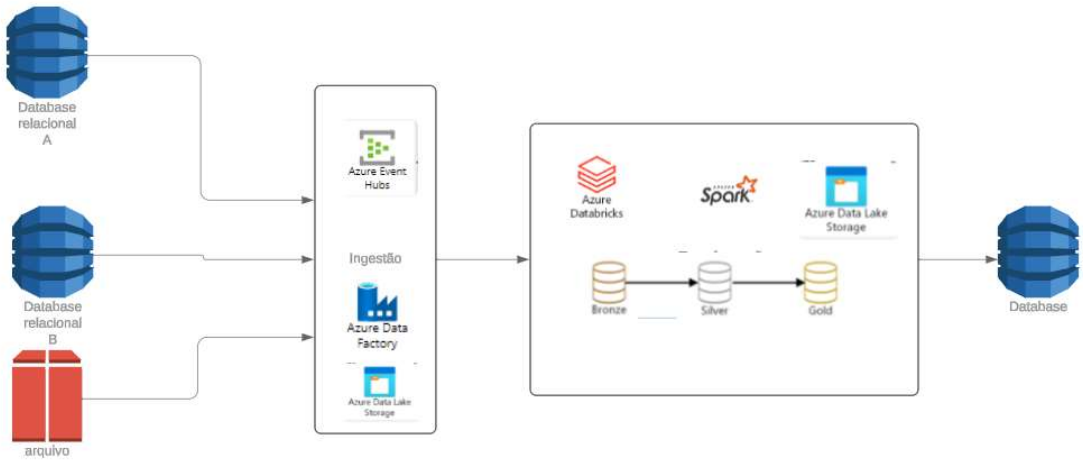

2. **Apache Spark e Databricks: Como o Databricks se integra ao Apache Spark? Quais são as principais vantagens do uso do Databricks em comparação com uma instalação padrão do Apache Spark?**
   R: Integração do Databricks com Spark: O Databricks foi construído em cima do Apache Spark e utiliza clusters para o processamento de grandes volumes de dados de forma distribuída. A plataforma também possui recursos para construção de pipelines, permitindo que os usuários processem dados em etapas e visualizem os resultados em tempo real.
   Vantagens do Databricks. Na plataforma do Databricks dentro do notebook podemos trabalhar com várias linguagens de programação como por exemplo o Scala, R, SQL, etc., em apenas um notebook você pode misturar as linguagens. Além dos armazenamentos internos como os DBFS.

3. **Notebooks e Linguagens de Programação: Explique como você usaria Notebooks no Databricks para criar e executar código. Além disso, como o Databricks suporta várias linguagens de programação, e como você decidiria qual linguagem usar em um projeto específico?**

R: Para o uso de notebooks, o usuário precisa entrar na plataforma do databricks, pode ser inclusive a Community, dentro da área de Data Science & Engenieering no menu lateral esquerdo na opção “Create -> Notebook”. Os notebooks podem ser usados para criar um pipeline de ETL (Extract Transform e Load), usando as linguagens que o databricks suporte. Entre elas o python. Por prática comum, é comum, para criar um pipeline de ETL deve-se criar 3 notebooks um para extração dos dados como é na origem, chamado de camada Bronze, outro para a tratamento dos dados, chamado de camada Silver e outro para fazer agregações entre outras transformações, chamado de camada Gold. A escolha da linguagem depende do volume de dados que o usuário está trabalhando. Para ganhar poder de processamento é comum utilizar os comandos em Spark onde o processamento ocorre de forma distribuída. Além disso a escolha também pode ser com base na afinidade do usuário.

4. **Integração de Fontes de Dados: Como o Databricks facilita a integração com diferentes fontes de dados, como Data Lakes, bancos de dados relacionais e fontes externas? Você pode fornecer um exemplo prático de como lidar com essas integrações?**
   R: O Databricks possui diversos padrões que possibilitam integração com diversas fontes de dados, entre elas conexão com fontes externas de dados, fazendo uso de API Rest fornecendo um endpoint unificado para gerenciar a plataforma. Além disso conectores otimizados que possibilitam a ingestão de dados no Data Lake, por exemplo JDBC entre outros. Muitos dos bancos de dados já tem seu run-time incluído no Databricks Runtime. Como exemplo posso citar a integração com um Storage da Azure por exemplo, onde é possível ler arquivos de diversas tipos, JSON, CSV, etc. Para isso basta montar o drive com a chave de acesso ao storage, no notebook e fazer a leitura e gravação dos arquivos.

5. **Machine Learning no Databricks: Descreva a abordagem que você seguiria para desenvolver e treinar modelos de machine learning no Databricks. Quais são as principais ferramentas e bibliotecas que você usaria para esse fim?**
   R: A plataforma disponibiliza um área específica para Machine Learning, que inclusive o nome é Machine Learning. Nessa área é possível criar notebooks também, para ler as bases do Databricks DBFS ou arquivos no storage. Dentro dos notebooks é possível criar modelos de machine learning, por exemplo rede neural etc. Além disso é possível criar painéis e visualização de dados. O Databricks Runtime for Machine Learning é o responsável por tudo isso, com clusters que integram versões compatíveis das bibliotecas mais comuns, como TensorFlow, PyTorch e Keras, também incluem suporte de GPU pré-configurado com drivers e biblioteca de suporte.

6. **Segurança e Controle de Acesso: Como o Databricks aborda questões de segurança e controle de acesso? Quais são as práticas recomendadas para garantir a proteção dos dados e ambientes de desenvolvimento?**
   R: A plataforma possui controles de acessos que garante que cada usuário só tenha acesso ao que ele precisa dentro da plataforma. Inclusive é possível o trabalho colaborativo, por exemplo ao mesmo tempo que um usuário está criando pipeline de dados outros usuários com perfil de cientista de dados por exemplo, podem acessar os dados já carregados. O acesso pode ser dados por grupo de usuários ou usuários individuais. Além disso é compatível com as clouds mais comuns (Azure, AWS e GCP).

7. **Desafios e Soluções: Pergunta: Conte-nos sobre um desafio específico que você enfrentou ao trabalhar com Databricks e como o resolveu. Qual foi a solução implementada e quais foram os resultados alcançados?**
   R: Em um projeto que trabalhei, tive que criar um ETL para carregar dados de uma fonte de dados que era muito grande, com bilhões de registros BigQuery da GCP). O pipeline estava se perdendo com a volumetria e demorando muito. Então fiz uma implementação usando o Airflow e o ptyhon, lendo os registros de forma quebrada (particionada). Com isso resolveu meu problema que tive e a carga ficou mais rápida.

8. **Conjunto de Dados do Kaggle:** Escolha um conjunto de dados do Kaggle relacionado a vendas. Certifique-se de que o conjunto de dados inclui informações como datas, produtos, quantidades vendidas, etc.
   Projeto de Engenharia de Dados:
   Ingestão e Carregamento de Dados: Carregue o conjunto de dados no Databricks. Explore o esquema dos dados e faça ajustes conforme necessário.
   Transformações de Dados: Realize transformações necessárias, como tratamento de valores nulos, conversões de tipos, etc. Adicione uma coluna calculada, por exemplo, o valor total de cada transação. Agregue os dados para obter estatísticas de vendas, por exemplo, o total de vendas por produto ou por categoria. Introduza uma regra mais complexa, como identificar padrões de comportamento de compra ao longo do tempo ou criar categorias personalizadas de produtos com base em determinados critérios.
   Saída em Parquet e Delta: Grave os dados transformados e agregados em um formato Parquet para persistência eficiente. Grave os mesmos dados em formato Delta Lake para aproveitar as funcionalidades de versionamento e transações ACID.
   Exploração Adicional (Opcional): Execute consultas exploratórias para entender melhor os dados e validar as transformações. Crie visualizações ou relatórios para comunicar insights. Agende o notebook para execução automática em intervalos regulares para garantir a atualização contínua dos dados

   SOLUÇÃO
   Base de dados utilizada: https://www.kaggle.com/datasets/kyanyoga/sample-sales-data

   Notebook 1 (Camada Bronze)
   Comandos:

```
from datetime import datetime
source_origin_param = "dbfs:/FileStore/FileStore/"
dest_origin_param   =
"dbfs:/FileStore/FileStore/Vendas_Bronze/extracted_at=%s" %
datetime.now().strftime('%Y-%m-%d')
extracted_at_param  =  datetime.now().strftime('%Y-%m-%d')

RAW_PATH = "{}{}".format(source_origin_param,  'sales_data_sample.csv')
BRONZE_PATH = "{}/{}".format(dest_origin_param, 'sales_data_sample_bronze')

print(RAW_PATH)
```

```
print(BRONZE_PATH)
dfVendas = spark.read.format("csv").option("header", "true").load(RAW_PATH)
dfVendas.display()
PARQUET_PATH = BRONZE_PATH + '.parquet'
dfVendas.write.format("parquet").mode("overwrite").save(PARQUET_PATH)
DELTA_PATH = BRONZE_PATH + '.delta'
dfVendas.write.format("delta").mode("overwrite").save(DELTA_PATH)
```

Telas da execução:

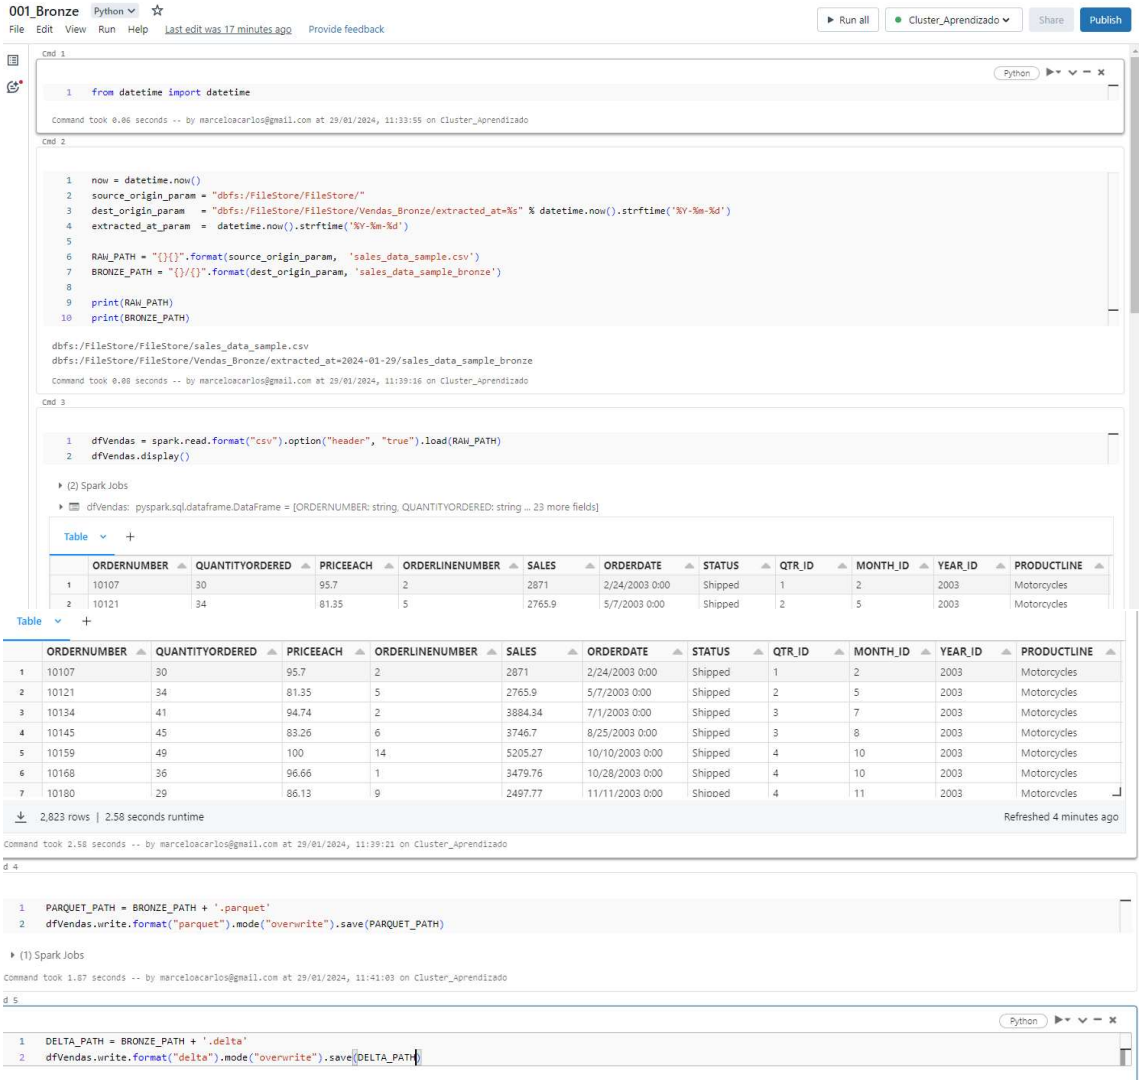

Notebook 2 (Camada Silver)
Comandos:

```
from datetime import datetime
from pyspark.sql.functions import lit

source_origin_param =
"dbfs:/FileStore/FileStore/Vendas_Bronze/extracted_at=%s" %
datetime.now().strftime('%Y-%m-%d')
```

```
dest_origin_param   =
"dbfs:/FileStore/FileStore/Vendas_Silver/extracted_at=%s" %
datetime.now().strftime('%Y-%m-%d')
extracted_at_param  =  datetime.now().strftime('%Y-%m-%d')

BRONZE_PATH = "{}/{}".format(source_origin_param, 'sales_data_sample_bronze')
SILVER_PATH = "{}/{}".format(dest_origin_param, 'sales_data_sample_silver')

print(BRONZE_PATH)
print(SILVER_PATH)
BRONZE_PATH_DELTA = BRONZE_PATH + ".delta"
print(BRONZE_PATH_DELTA)
dfVendas =
spark.read.option("fetchsize","100000").format("delta").load(BRONZE_PATH_DELT
A)
dfVendas.display()

now =  datetime.now().strftime('%Y-%m-%d')
dfVendas_Silver = dfVendas
dfVendas_Silver = dfVendas_Silver \
            .withColumn('ORDERDATE',dfVendas_Silver['ORDERDATE'].cast('date')
) \
            .withColumn('ORDERNUMBER',dfVendas_Silver['ORDERNUMBER'].cast('in
t')) \
            .withColumn('QTR_ID',dfVendas_Silver['QTR_ID'].cast('int')) \
            .withColumn('MONTH_ID',dfVendas_Silver['MONTH_ID'].cast('int')) \
            .withColumn('YEAR_ID',dfVendas_Silver['YEAR_ID'].cast('int')) \
            .withColumn('MSRP',dfVendas_Silver['MSRP'].cast('int')) \
            .withColumn('ORDERLINENUMBER',dfVendas_Silver['ORDERLINENUMBER'].
cast('int')) \
            .withColumn('QUANTITYORDERED',dfVendas_Silver['QUANTITYORDERED'].
cast('int')) \
            .withColumn('SALES',dfVendas_Silver['SALES'].cast('float')) \
            .withColumn('PRICEEACH',dfVendas_Silver['PRICEEACH'].cast('float'
)) \
            .withColumn("DATA_CARGA",lit(now).cast('date'))
dfVendas_Silver.printSchema()

SILVER_PATH = SILVER_PATH + '.delta'
dfVendas_Silver.write.format("delta").mode("overwrite").save(SILVER_PATH)
```

TELAS:

002_Silver

Python

File Edit View Run Help Last edit was 21 minutes ago Provide feedback

Cmd 1

```
from datetime import datetime
source_origin_param = "dbfs:/FileStore/FileStore/Vendas_Bronze/extracted_at=%s" % datetime.now().strftime('%Y-%m-%d')
dest_origin_param   = "dbfs:/FileStore/FileStore/Vendas_Silver/extracted_at=%s" % datetime.now().strftime('%Y-%m-%d')
extracted_at_param  =  datetime.now().strftime('%Y-%m-%d')

BRONZE_PATH = "{}/{}".format(source_origin_param, 'sales_data_sample_bronze')
SILVER_PATH = "{}/{}".format(dest_origin_param, 'sales_data_sample_silver')

print(BRONZE_PATH)
print(SILVER_PATH)
```

```
dbfs:/FileStore/FileStore/Vendas_Bronze/extracted_at=2024-01-29/sales_data_sample_bronze
dbfs:/FileStore/FileStore/Vendas_Silver/extracted_at=2024-01-29/sales_data_sample_silver
```

Command took 0.13 seconds -- by marceloacarlos@gmail.com at 29/01/2024, 14:35:21 on Cluster_Aprendizado

Cmd 2

```
BRONZE_PATH_DELTA = BRONZE_PATH + ".delta"
print(BRONZE_PATH_DELTA)
dfVendas = spark.read.option("fetchsize","100000").format("delta").load(BRONZE_PATH_DELTA)
dfVendas.display()
```

▸ (1) Spark Jobs

▸ dfVendas: pyspark.sql.dataframe.DataFrame = [ORDERNUMBER: string, QUANTITYORDERED: string ... 23 more fields]

```
dbfs:/FileStore/FileStore/Vendas_Bronze/extracted_at=2024-01-29/sales_data_sample_bronze.delta
```

	ORDERNUMBER	QUANTITYORDERED	PRICEEACH	ORDERLINENUMBER	SALES	ORDERDATE	STATUS	QTR_ID	MONTH_ID	YEAR_ID	PRODUCTLINE
1	10107	30	95.7	2	2871	2/24/2003 0:00	Shipped	1	2	2003	Motorcycles
2	10121	34	81.35	5	2765.9	5/7/2003 0:00	Shipped	2	5	2003	Motorcycles
3	10134	41	94.74	2	3884.34	7/1/2003 0:00	Shipped	3	7	2003	Motorcycles
4	10145	45	83.26	6	3746.7	8/25/2003 0:00	Shipped	3	8	2003	Motorcycles
5	10159	49	100	14	5205.27	10/10/2003 0:00	Shipped	4	10	2003	Motorcycles
6	10168	36	96.66	1	3479.76	10/28/2003 0:00	Shipped	4	10	2003	Motorcycles
7	10180	29	86.13	9	2497.77	11/11/2003 0:00	Shipped	4	11	2003	Motorcycles

2,823 rows | 1.58 seconds runtime Refreshed 17 minutes ago

Command took 1.58 seconds -- by marceloacarlos@gmail.com at 29/01/2024, 14:40:20 on Cluster_Aprendizado

md 3

```
now =  datetime.now().strftime('%Y-%m-%d')
dfVendas_Silver = dfVendas
dfVendas_Silver = dfVendas_Silver \
            .withColumn('ORDERDATE',dfVendas_Silver['ORDERDATE'].cast('date')) \
            .withColumn('ORDERNUMBER',dfVendas_Silver['ORDERNUMBER'].cast('int')) \
            .withColumn('QTR_ID',dfVendas_Silver['QTR_ID'].cast('int')) \
            .withColumn('MONTH_ID',dfVendas_Silver['MONTH_ID'].cast('int')) \
            .withColumn('YEAR_ID',dfVendas_Silver['YEAR_ID'].cast('int')) \
            .withColumn('MSRP',dfVendas_Silver['MSRP'].cast('int')) \
            .withColumn('ORDERLINENUMBER',dfVendas_Silver['ORDERLINENUMBER'].cast('int')) \
            .withColumn('QUANTITYORDERED',dfVendas_Silver['QUANTITYORDERED'].cast('int')) \
            .withColumn('SALES',dfVendas_Silver['SALES'].cast('float')) \
            .withColumn('PRICEEACH',dfVendas_Silver['PRICEEACH'].cast('float')) \
            .withColumn("DATA_CARGA",lit(now).cast('date'))
dfVendas_Silver.printSchema()
```

▸ dfVendas_Silver: pyspark.sql.dataframe.DataFrame = [ORDERNUMBER: integer, QUANTITYORDERED: integer ... 24 more fields]

```
|-- STATUS: string (nullable = true)
|-- QTR_ID: integer (nullable = true)
|-- MONTH_ID: integer (nullable = true)
|-- YEAR_ID: integer (nullable = true)
|-- PRODUCTLINE: string (nullable = true)
|-- MSRP: integer (nullable = true)
|-- PRODUCTCODE: string (nullable = true)
|-- CUSTOMERNAME: string (nullable = true)
|-- PHONE: string (nullable = true)
|-- ADDRESSLINE1: string (nullable = true)
|-- ADDRESSLINE2: string (nullable = true)
|-- CITY: string (nullable = true)
|-- STATE: string (nullable = true)
```

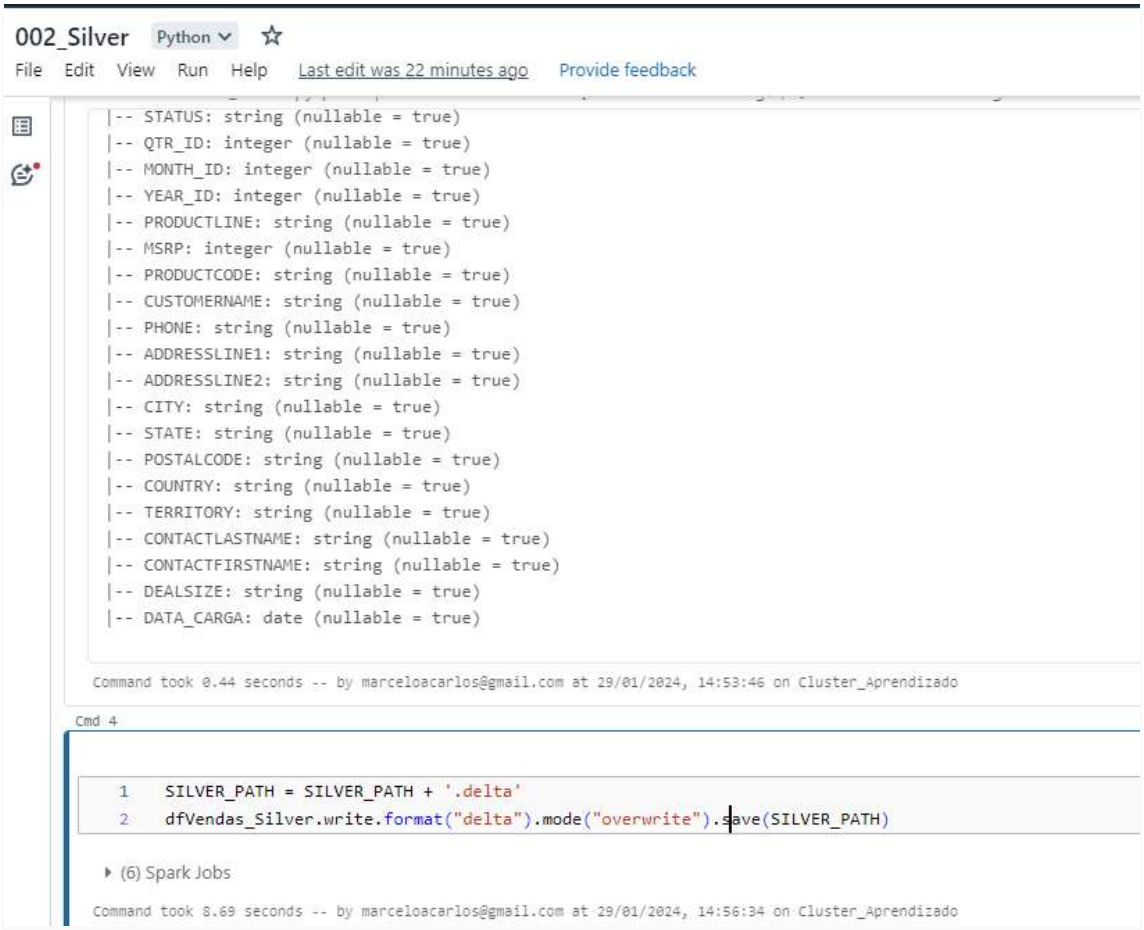

Notebook 3 (Camada Gold)
Comandos:

```
from datetime import datetime
from pyspark.sql.functions import lit

source_origin_param =
"dbfs:/FileStore/FileStore/Vendas_Silver/extracted_at=%s" %
datetime.now().strftime('%Y-%m-%d')
dest_origin_param   = "dbfs:/FileStore/FileStore/Vendas_Gold/extracted_at=%s"
% datetime.now().strftime('%Y-%m-%d')
extracted_at_param  =  datetime.now().strftime('%Y-%m-%d')

SILVER_PATH = "{}/{}".format(source_origin_param, 'sales_data_sample_silver')
GOLD_PATH = "{}/{}".format(dest_origin_param, 'sales_data_sample_gold')

print(SILVER_PATH)
print(GOLD_PATH)
SILVER_PATH_DELTA = SILVER_PATH + ".delta"
print(SILVER_PATH_DELTA)
```

```
dfVendas =
spark.read.option("fetchsize","100000").format("delta").load(SILVER_PATH_DELT
A)
dfVendas.display()
dfVendas_Gold = dfVendas
dfVendas_Gold = dfVendas_Gold \
    .withColumn("TOTAL_PRODUTOS", dfVendas_Gold.QUANTITYORDERED *
dfVendas_Gold.PRICEEACH)
```

```
#gravando a saída GOLD
PARQUET_PATH = GOLD_PATH + '.parquet'
dfVendas_Gold.write.format("parquet").mode("overwrite").save(PARQUET_PATH)

GOLD_PATH = GOLD_PATH + '.delta'
dfVendas_Gold.write.format("delta").mode("overwrite").option("mergeSchema",
"true").partitionBy("YEAR_ID").save(GOLD_PATH)
```

```
from pyspark.sql.functions import sum, avg

# Soma
dfVendas_Gold.select(sum("TOTAL_PRODUTOS")).show()

#Agrupamento
dfVendas_Gold.groupBy("PRODUCTLINE").agg(avg("SALES")).show()
```

```
spark.sql("""
          CREATE DATABASE IF NOT EXISTS TESTE_DATABRICKS
          """)
```

```
spark.sql("""
          USE TESTE_DATABRICKS
""")
spark.sql("""
    DROP TABLE IF EXISTS VENDAS
""")

spark.sql(f"""
    CREATE TABLE VENDAS
    USING DELTA
    LOCATION '{GOLD_PATH}'
""")
```

```
df_gold = spark.sql("""SELECT * FROM TESTE_DATABRICKS.VENDAS""")
display(df_gold)
```

```
# cria tabela agregada
colunas_selecionadas = ["YEAR_ID","MONTH_ID","PRODUCTLINE","CITY"]
df_gold_agg =
df_gold.groupBy(colunas_selecionadas).agg(sum("QUANTITYORDERED").alias("QTDE_
TOTAL_VENDA"),sum("SALES").alias("TOTAL_VENDA"))
display(df_gold_agg)
```

```
#gravando a saída GOLD
PARQUET_PATH = GOLD_PATH + '_agg.parquet'
df_gold_agg.write.format("parquet").mode("overwrite").save(PARQUET_PATH)

GOLD_PATH = GOLD_PATH + '_agg.delta'
df_gold_agg.write.format("delta").mode("overwrite").option("mergeSchema",
"true").partitionBy("YEAR_ID").save(GOLD_PATH)
```

TELAS:

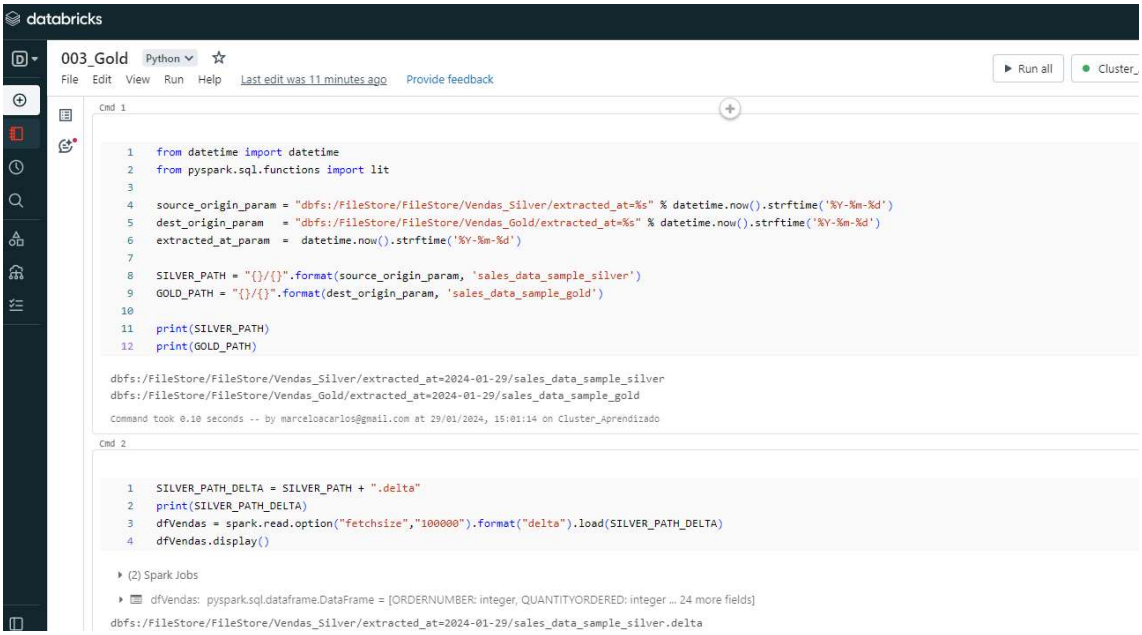

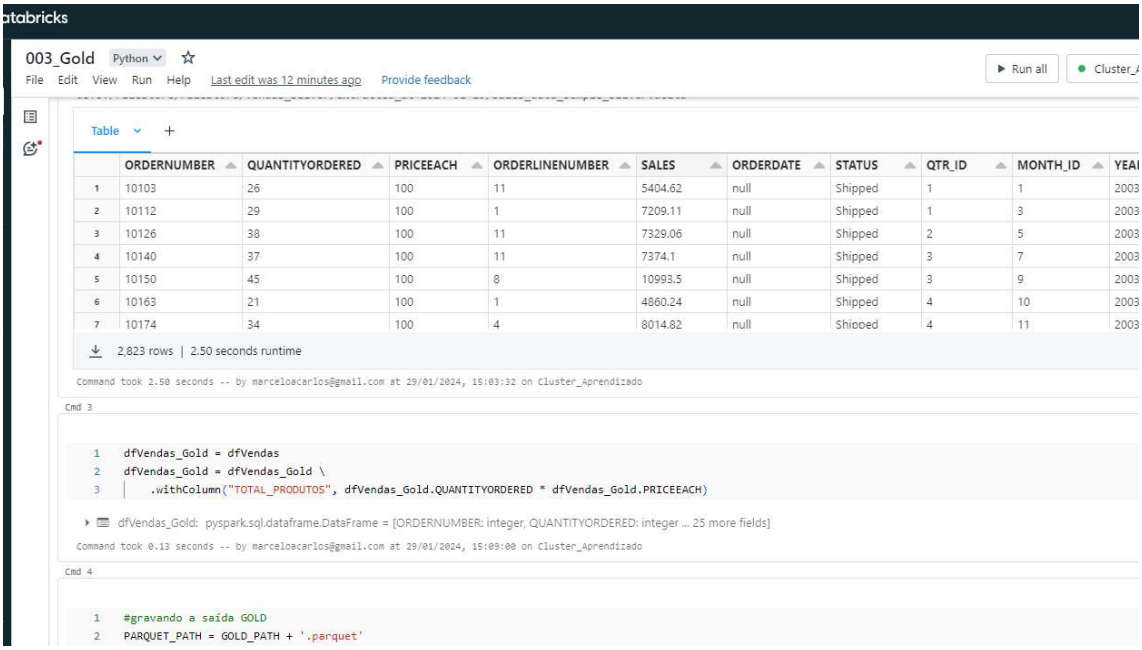
databricks
003_Gold
Python
File Edit View Run Help
Last edit was 12 minutes ago
Provide feedback
Run all
Table
ORDERNUMBER QUANTITYORDERED PRICEEACH ORDERLINENUMBER SALES ORDERDATE STATUS QTR_ID MONTH_ID YEAI
1 10103 26 100 11 5404.62 null Shipped 1 1 2003
2 10112 29 100 1 7209.11 null Shipped 1 3 2003
3 10126 38 100 11 7329.06 null Shipped 1 5 2003
4 10140 37 100 11 7374.1 null Shipped 3 7 2003
5 10150 45 100 8 10993.5 null Shipped 3 9 2003
6 10163 21 100 1 4860.24 null Shipped 4 10 2003
7 10174 34 100 4 8014.82 null Shipped 4 11 2003
2,823 rows | 2.50 seconds runtime
Command took 2.50 seconds -- by marceloacarlos@gmail.com at 29/01/2024, 15:03:32 on Cluster_Aprendizado
Cmd 3
1 dfVendas_Gold = dfVendas
2 dfVendas_Gold = dfVendas_Gold \
3 .withColumn("TOTAL_PRODUTOS", dfVendas_Gold.QUANTITYORDERED * dfVendas_Gold.PRICEEACH)
dfVendas_Gold: pyspark.sql.dataframe.DataFrame = [ORDERNUMBER: integer, QUANTITYORDERED: integer ... 25 more fields]
Command took 0.13 seconds -- by marceloacarlos@gmail.com at 29/01/2024, 15:09:00 on Cluster_Aprendizado
Cmd 4
1 #gravando a saída GOLD
2 PARQUET_PATH = GOLD_PATH + '.parquet'

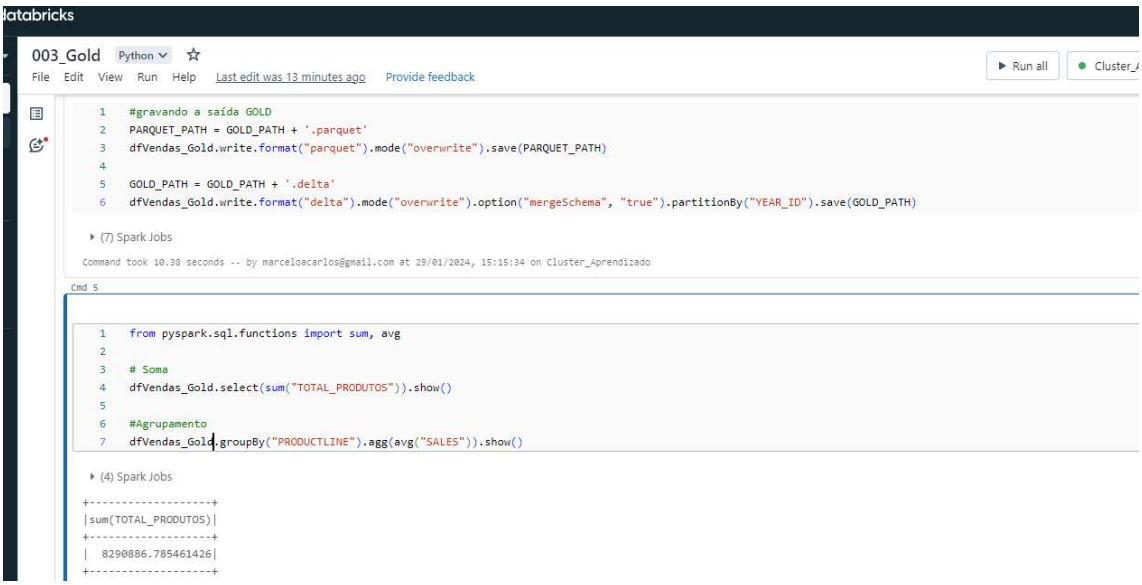
databricks
003_Gold
Python
File Edit View Run Help
Last edit was 13 minutes ago
Provide feedback
Run all
1 #gravando a saída GOLD
2 PARQUET_PATH = GOLD_PATH + '.parquet'
3 dfVendas_Gold.write.format("parquet").mode("overwrite").save(PARQUET_PATH)
4
5 GOLD_PATH = GOLD_PATH + '.delta'
6 dfVendas_Gold.write.format("delta").mode("overwrite").option("mergeSchema", "true").partitionBy("YEAR_ID").save(GOLD_PATH)
(7) Spark Jobs
Command took 10.38 seconds -- by marceloacarlos@gmail.com at 29/01/2024, 15:15:34 on Cluster_Aprendizado
Cmd 5
1 from pyspark.sql.functions import sum, avg
2
3 # Soma
4 dfVendas_Gold.select(sum("TOTAL_PRODUTOS")).show()
5
6 #Agrupamento
7 dfVendas_Gold.groupBy("PRODUCTLINE").agg(avg("SALES")).show()
(4) Spark Jobs
+------------------+
|sum(TOTAL_PRODUTOS)|
+------------------+
| 8290886.785461426|
+------------------+

003_Gold Python

File Edit View Run Help Last edit was 22 hours ago Provide feedback

(4) Spark Jobs

```
+-------------------+
|sum(TOTAL_PRODUTOS)|
+-------------------+
|  8290886.785461426|
+-------------------+

+----------------+------------------+
|     PRODUCTLINE|        sum(SALES)|
+----------------+------------------+
|     Motorcycles|1166388.3392333984|
|    Vintage Cars| 1903150.835571289|
|           Ships| 714437.1301269531|
|Trucks and Buses|1127789.8432617188|
|    Classic Cars|3919615.6607666016|
|          Trains|226243.46899414062|
|          Planes| 975003.5713500977|
+----------------+------------------+
```

Command took 1.96 seconds -- by marceloacarlos@gmail.com at 29/01/2024, 16:35:36 on Cluster_Aprendizado

Cmd 6

```
spark.sql("""
          CREATE DATABASE IF NOT EXISTS TESTE_DATABRICKS
          """)
```

Out[28]: DataFrame[]

Command took 0.12 seconds -- by marceloacarlos@gmail.com at 29/01/2024, 16:21:07 on Cluster_Aprendizado

Cmd 7

databricks

003_Gold Python

File Edit View Run Help Last edit was 22 hours ago Provide feedback

```
spark.sql("""
          USE TESTE_DATABRICKS
""")
spark.sql("""
    DROP TABLE IF EXISTS VENDAS
""")

spark.sql(f"""
    CREATE TABLE VENDAS
    USING DELTA
    LOCATION '{GOLD_PATH}'
""")
```

Out[29]: DataFrame[]

Command took 0.22 seconds -- by marceloacarlos@gmail.com at 29/01/2024, 16:21:11 on Cluster_Aprendizado

Cmd 8

```
df_gold = spark.sql("""SELECT * FROM TESTE_DATABRICKS.VENDAS""")
display(df_gold)
```

(3) Spark Jobs

df_gold: pyspark.sql.dataframe.DataFrame = [ORDERNUMBER: integer, QUANTITYORDERED: integer ... 25 more fields]

Table +

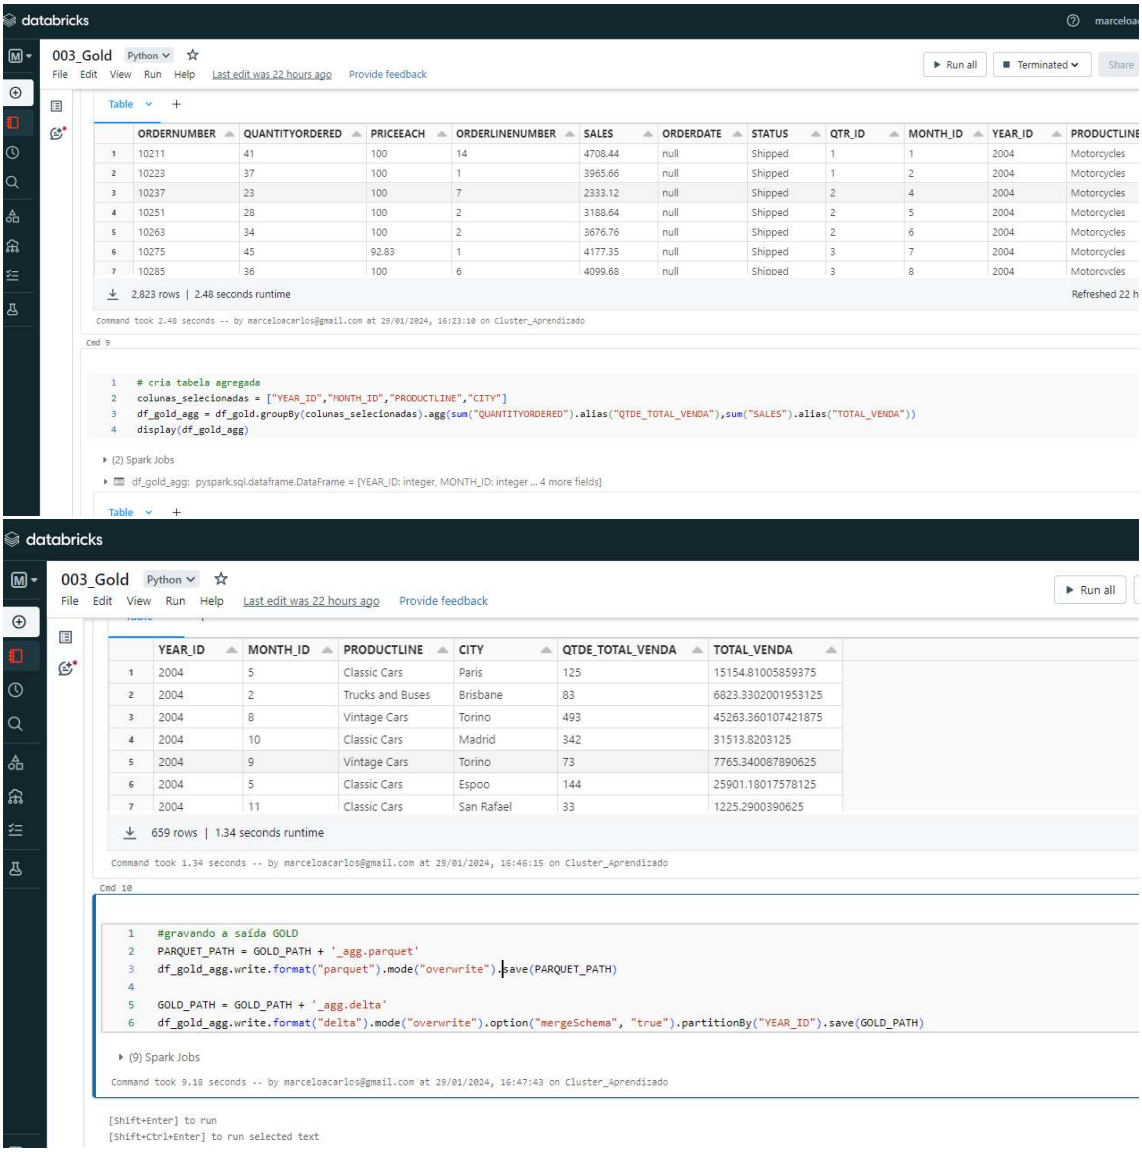
databricks
003_Gold
Python
File Edit View Run Help
Last edit was 22 hours ago
Provide feedback
Run all
Terminated
Share
Table
ORDERNUMBER | QUANTITYORDERED | PRICEEACH | ORDERLINENUMBER | SALES | ORDERDATE | STATUS | QTR_ID | MONTH_ID | YEAR_ID | PRODUCTLINE
1 10211 41 100 14 4708.44 null Shipped 1 1 2004 Motorcycles
2 10223 37 100 1 3965.66 null Shipped 1 2 2004 Motorcycles
3 10237 23 100 7 2333.12 null Shipped 2 4 2004 Motorcycles
4 10251 28 100 2 3188.64 null Shipped 2 5 2004 Motorcycles
5 10263 34 100 2 3676.76 null Shipped 2 6 2004 Motorcycles
6 10275 45 92.83 1 4177.35 null Shipped 3 7 2004 Motorcycles
7 10285 36 100 6 4099.68 null Shipped 3 8 2004 Motorcycles
2,823 rows | 2.48 seconds runtime
Refreshed 22 h
Command took 2.48 seconds -- by marceloacarlos@gmail.com at 29/01/2024, 16:23:10 on Cluster_Aprendizado
Cmd 9
# cria tabela agregada
colunas_selecionadas = ["YEAR_ID","MONTH_ID","PRODUCTLINE","CITY"]
df_gold_agg = df_gold.groupBy(colunas_selecionadas).agg(sum("QUANTITYORDERED").alias("QTDE_TOTAL_VENDA"),sum("SALES").alias("TOTAL_VENDA"))
display(df_gold_agg)
(2) Spark Jobs
df_gold_agg: pyspark.sql.dataframe.DataFrame = [YEAR_ID: integer, MONTH_ID: integer ... 4 more fields]
Table

databricks
003_Gold
Python
File Edit View Run Help
Last edit was 22 hours ago
Provide feedback
Run all
YEAR_ID | MONTH_ID | PRODUCTLINE | CITY | QTDE_TOTAL_VENDA | TOTAL_VENDA
1 2004 5 Classic Cars Paris 125 15154.81005859375
2 2004 2 Trucks and Buses Brisbane 83 6823.3302001953125
3 2004 8 Vintage Cars Torino 493 45263.360107421875
4 2004 10 Classic Cars Madrid 342 31513.8203125
5 2004 9 Vintage Cars Torino 73 7765.340087890625
6 2004 5 Classic Cars Espoo 144 25901.18017578125
7 2004 11 Classic Cars San Rafael 33 1225.2900390625
659 rows | 1.34 seconds runtime
Command took 1.34 seconds -- by marceloacarlos@gmail.com at 29/01/2024, 16:46:15 on Cluster_Aprendizado
Cmd 10
#gravando a saída GOLD
PARQUET_PATH = GOLD_PATH + '_agg.parquet'
df_gold_agg.write.format("parquet").mode("overwrite").save(PARQUET_PATH)
GOLD_PATH = GOLD_PATH + '_agg.delta'
df_gold_agg.write.format("delta").mode("overwrite").option("mergeSchema", "true").partitionBy("YEAR_ID").save(GOLD_PATH)
(9) Spark Jobs
Command took 9.18 seconds -- by marceloacarlos@gmail.com at 29/01/2024, 16:47:43 on Cluster_Aprendizado
[Shift+Enter] to run
[Shift+Ctrl+Enter] to run selected text

```python
from pyspark.sql.functions import sum, avg

# Soma
dfVendas_Gold.select(sum("TOTAL_PRODUTOS")).show()

#Agrupamento
dfVendas_Gold.groupBy("PRODUCTLINE").agg(avg("SALES")).show()
```

▸ (4) Spark Jobs

```
+-------------------+
|sum(TOTAL_PRODUTOS)|
+-------------------+
|  8290886.785461426|
+-------------------+

+----------------+------------------+
|     PRODUCTLINE|        avg(SALES)|
+----------------+------------------+
|     Motorcycles| 3523.831840584285|
|    Vintage Cars|3135.3391030828484|
|           Ships| 3053.150128747663|
|Trucks and Buses| 3746.810110504049|
|    Classic Cars|4053.3771052395055|
|          Trains|2938.2268700537743|
|          Planes| 3186.286180882672|
+----------------+------------------+
```